

Preguntas de asesor — Defensa de proyecto

Reconocimiento de marcha (Gait Recognition) · GaitBase fine-tune · 19 sujetos · pipeline en vivo · checkpoint 2026-05-07

Bloque 1 — Motivacion y problema

P1. Por que reconocimiento por marcha y no por rostro o huella?

La marcha es biometrica **a distancia y sin cooperacion del sujeto**: no requiere mirar a una camara ni tocar un sensor. Funciona con baja resolucion, oclusion parcial de cara y con ropa cubriendo extremidades. Para pase de lista es ideal porque no interrumpe el flujo de personas. La huella o el rostro requieren proximidad o cooperacion; la marcha no.

P2. Por que no usar simplemente un sistema comercial?

Porque (a) los sistemas comerciales de gait son caros y propietarios, (b) el objetivo del proyecto es **aplicar y validar el estado del arte open-source en condiciones reales**, no comprar una caja negra, y (c) entrenar/calibrar localmente permite adaptarse a la camara y al ambiente especificos del aula.

P3. Cual es exactamente el problema que resuelves?

Identificacion **open-set** de 19 sujetos a 90 grados lateral en video continuo, distinguiendo enrolados de no-enrolados, en tiempo casi-real con hardware modesto (GTX 1650).

Bloque 2 — Estado del arte

P4. Que metodos de gait existen y cual elegiste?

Tres familias: **basados en silueta** (GEI, GaitSet, GaitGL, GaitBase, DeepGaitV2) que usan mascararas binarias; **basados en esqueleto/pose** (PoseGait, GaitGraph, SkeletonGait); y **multimodales** (SkeletonGait++) que combinan ambos. Elegí **GaitBase** porque (1) es el baseline oficial de OpenGait, (2) tiene preentrenamiento en Gait3D con 4,000 sujetos, (3) arquitectura simple y reproducible, (4) mejor compromiso accuracy/velocidad para mi hardware.

P5. Probaste el multimodal? Por que lo descartaste?

Si, entreno SkeletonGait++ (iter1000). **No mejoro** sobre GaitBase puro en este angulo y volumen de datos. La razon: a 90 grados lateral la silueta ya captura casi toda la informacion discriminativa; agregar pose introduce ruido del estimador de keypoints sin agregar senal nueva. Decision basada en evidencia empirica, documentada.

P6. Que es Gait3D y por que importa?

Gait3D es un dataset publico con **4,000 sujetos en escenarios reales** (no laboratorio). El preentrenamiento en Gait3D le dio al modelo un espacio de embedding general antes del fine-tuning con mis 19 sujetos. Sin transfer learning, 19 sujetos serian insuficientes para entrenar desde cero.

Bloque 3 — Dataset

P7. Cuantos sujetos, cuantas sesiones, que condiciones?

19 sujetos, 2 sesiones separadas en el tiempo, **90 grados lateral**, ropa similar entre sesiones. 13 de los 19 se usaron en fine-tune; los 6 restantes solo aparecen en galeria (validan transfer del espacio aprendido).

P8. Por que solo 90 grados?

Por restriccion de tiempo y porque el escenario objetivo (entrada a aula) es controlable: la camara se monta perpendicular al paso. Es una **limitacion documentada** — para multi-vista necesitarías re-grabar con varios angulos, lo que el dataset actual no permite.

P9. Por que solo 2 sesiones?

2 sesiones es el **minimo** para evaluar generalizacion temporal (entrenas con s1, evaluas con s2 y viceversa). Con 1 sola sesion el modelo memoriza condiciones especificas del dia (iluminacion, ropa exacta). Con 2 ya puedes medir si el embedding es estable.

P10. Como evitas overfitting con dataset chico?

(1) Transfer learning desde Gait3D, (2) **fine-tune corto** (iter 1,200 con early stopping por validacion), (3) augmentation estandar de OpenGait (flip horizontal, perspective), (4) weight decay en SGD, (5) leave-camera-out / multisession split para que train y test nunca compartan sesion.

Bloque 4 — Arquitectura

P11. Explicame tu arquitectura en una frase.

ResNet9 2D que procesa cada frame como imagen independiente → max-pooling temporal sobre la secuencia → Horizontal Pooling Pyramid en 16 franjas anatomicas → 16 FCs separadas → embedding (256, 16) = 4,096-D L2-normalizado.

P12. Por que max temporal y no LSTM o 3D-conv?

Empiricamente, en GaitBase el max temporal supera o iguala a alternativas mas complejas con menos computo. La marcha es periodica: el max captura la pose extrema de cada feature a lo largo del ciclo. LSTM/3D-conv son utiles cuando la dinamica temporal fina importa; en gait, la **envolvente** del movimiento es suficiente.

P13. Que es la Horizontal Pooling Pyramid (HPP)?

Divide el feature map en **16 franjas horizontales** (cabeza, cuello, hombros, ..., pies) y hace pooling en cada una. Cada franja captura una zona anatomica. Las 16 FCs separadas aprenden representaciones distintas por zona — la firma de marcha vive en como se mueven esas zonas relativamente.

P14. Por que 256 dimensiones por parte y no 512 o 128?

Es el valor estandar de OpenGait/GaitBase. $256 \times 16 = 4,096$ -D total. Mas dimensiones aumentan capacidad y costo de matching; menos sacrifican discriminacion. No hay justificacion teorica fuerte, si

empirica del paper.

Bloque 5 — Entrenamiento

P15. Que perdida usaste?

Triplet loss sobre embeddings (separacion metrica) + **Cross-Entropy** sobre las cabezas BNNeck (clasificacion de las 13 clases vistas). Es el esquema multi-loss estandar en re-id: triplet da el espacio metrico, CE estabiliza el entrenamiento.

P16. Optimizador e hiperparametros?

SGD con momentum 0.9, weight decay 5e-4, MultiStepLR. LR de fine-tune mucho menor que el de preentrenado (orden de 1e-3 o menos) para no destruir los pesos de Gait3D.

P17. Por que iteracion 1,200?

Early stopping por validacion: la metrica en validacion dejo de mejorar y empezo a degradar (overfitting). 1,200 fue el best — lo demas se descarto.

P18. Cuanto tardo el fine-tune?

Aproximadamente 1-3 horas en GTX 1650 para iter 1,200 con dataset pequeno (verificable contra los logs de entrenamiento).

Bloque 6 — Evaluacion

P19. Que metricas reportas y que significan?

EER (Equal Error Rate) = 8.11%: punto donde FAR = FRR. Resumen general del modelo.
TAR@FAR=0% = 86.49%: con CERO falsos positivos, identificas correctamente al 86.49% de los genuinos — esta es la metrica operativa, en pase de lista marcar a alguien como otro es inaceptable.
tau = 0.9847: umbral calibrado para alcanzar FAR=0% absoluto.

P20. Como elegiste tau?

Calibracion en validacion: barrido de tau desde 0 hasta 1, encuentro el menor tau que da FAR=0% en pares impostor del split de validacion. **No se ajusto en test** (hubiera sido data leakage).

P21. Por que FAR=0% y no FAR=1%?

Porque en pase de lista un falso positivo es **peor** que un falso negativo. Si marcas a Pedro como Juan, el sistema falla silenciosamente. Si rechazas a Juan, el insiste o se reintenta. Asimetria operacional.

P22. Que es un open-set y por que importa aqui?

Open-set = el sistema debe **rechazar** identidades no enroladas, no solo elegir la mas parecida entre las conocidas. Closed-set siempre devuelve un nombre; open-set devuelve desconocido si la similitud al mejor match es menor que tau. **Confirmado en vivo el 2026-05-06:** persona no enrolada -> sim=0.9403 < 0.9847 -> UNK correcto.

P23. Que split usaste para validar?

Leave-Camera-Out / Multisession: train con s1, test con s2 (y vice-versa). Garantiza que ningun frame del entrenamiento aparece en evaluacion. Es el split estandar en OpenGait.

Bloque 7 — Pipeline en vivo

P24. Describe el pipeline end-to-end.

(1) Captura C920 a 15 fps. (2) Detector YOLOv11n -> bbox de persona (mayor area). (3) Tracker FSM con warmup 15 frames y reset 15 frames sin bbox. (4) Segmentacion RVM MobileNetV3 -> silueta binaria, crop y normalize a 64x44. (5) SequenceBuffer acumula ventana de 60 frames con stride 30. (6) GaitBase -> embedding 4,096-D. (7) Matcher max-sim contra galeria (19 sujetos, $K \leq 4$ templates). (8) Confirmacion $N=2$ ventanas consecutivas con $\text{sim} > \text{tau}$ -> escribe CSV.

P25. Por que $N=2$ confirmaciones?

Para reducir falsos positivos transitorios. Una sola ventana puede acertar por casualidad si la silueta es ruidosa; **2 ventanas consecutivas** con la misma identidad y $\text{sim} > \text{tau}$ son evidencia mucho mas fuerte. Costo: ~2-4 segundos extra de latencia.

P26. Por que RVM y no Mask R-CNN o U2Net?

RVM es **stateful entre frames** (mantiene memoria recurrente), produce siluetas **temporalmente consistentes** sin parpadeo, y corre en tiempo real en MobileNetV3. Mask R-CNN procesa frame a frame independiente -> siluetas inestables.

P27. Que FPS reales tienes?

~6-8 fps en GTX 1650, dominados por (a) RVM segmentacion, (b) embedding GaitBase. El detector y matcher son baratos. Suficiente para ventanas de 4 s con stride 2 s.

P28. Que pasa si dos personas entran al cuadro?

Politica actual: **bbox de mayor area**. Una persona a la vez. Es una limitacion operacional documentada — para multi-persona necesitarias tracking multi-objeto (DeepSORT/ByteTrack) y un buffer de secuencia por track-ID.

Bloque 8 — Limitaciones y criticas

P29. Por que falla el par ricardomora <-> hectorsanchez?

Build corporal muy similar (estatura, complexion, longitud de zancada). El embedding los acerca en el espacio metrico. Es una **limitacion inherente al modelo**, no del pipeline. Documentado. Mitigacion: mas sesiones o multi-vista.

P30. Si cambias la camara, funciona?

No directamente. tau debe recalibrarse y, dependiendo de optica/altura/distancia, conviene re-enrolar. Es una restriccion documentada — la calibracion a hardware especifico es estandar en biometria.

P31. Y si la persona viste muy diferente al día del enrolamiento?

Robustez no validada formalmente — esta pendiente en Fase 6.5. La silueta capta principalmente forma corporal y dinamica, no textura, así que un cambio de ropa **moderado** debería tolerarse; ropa muy holgada (abrigo largo) si degrada.

P32. 86.49% es bueno?

Para 19 sujetos con 2 sesiones a 90 grados con FAR=0%: **si, esta en el rango razonable** del estado del arte para datasets pequeños. CASIA-B con GaitBase reporta ~95%+ pero con ~10x mas datos por sujeto y splits mas balanceados. Es honesto reportar la limitacion de datos.

P33. Tu sistema es seguro contra suplantacion (spoofing)?

No formalmente evaluado. Un atacante podría grabar a un sujeto enrolado y reproducir el video frente a la cámara. Defensas posibles (no implementadas): liveness por profundidad, detección de pantalla, sensor IR. Limitacion de scope.

P34. Y la privacidad? Estas procesando biometricos.

Pregunta importante. Los **embeddings no son reversibles a video** sin acceso al modelo y galeria. El CSV almacena solo identidad + timestamp + similitud, no imagen. Pero formalmente, gait es dato biometrico y aplica regulacion (GDPR/leyes locales). En despliegue real requeriria consentimiento informado de los enrolados.

Bloque 9 — Trabajo futuro

P35. Que falta?

Fase 6.5: validacion end-to-end formal con TPR/FPR/latencia en vivo. **Fase 7:** quantizacion INT8/TensorRT (objetivo: 30 ms vs 100 ms actual), SQLite en lugar de CSV, manual de calibracion. **Largo plazo:** multi-vista, multi-persona simultanea, robustez a ropa/occlusion.

P36. Si tuvieras 6 meses mas, que harias?

(1) Re-grabar dataset con 3-4 angulos. (2) Duplicar sesiones a 4-6 por sujeto en condiciones variadas. (3) Entrenar DeepGaitV2 (sucesor de GaitBase, mejor accuracy). (4) Integrar tracking multi-persona. (5) Dashboard web para administrar la galeria sin tocar codigo.

Bloque 10 — Preguntas trampa

P37. Que hiciste TU y que viene del paper/repo?

Vino de OpenGait: arquitectura GaitBase, codigo de entrenamiento, preentrenado Gait3D. **Trabajo propio:** dataset completo (19 sujetos, 2 sesiones, captura/anotacion), pipeline en vivo end-to-end, calibracion open-set, integracion RVM+YOLO+GaitBase, FSM tracker, logica de confirmacion, evaluacion formal, comparacion multimodal vs unimodal con decision justificada.

P38. Si te lo pidieran, podrias reproducir todo desde cero?

Si: dataset documentado, scripts versionados, configs en YAML, checkpoints guardados, reportes por fase en reports/. Cualquiera con el dataset y el repo puede reproducir el resultado.

P39. Cual es tu contribucion cientifica vs. de ingenieria?

Predominantemente ingenieria aplicada: integracion de componentes del SOTA en un sistema funcional con evaluacion honesta. La contribucion cientifica menor esta en la **evaluacion comparativa de multimodal vs unimodal a 90 grados** con evidencia de que el multimodal no aporta en este regimen — un dato util para futuros proyectos.

P40. Por que deberia aprobarse este proyecto?

Porque demuestra: (a) dominio del SOTA en gait, (b) capacidad de integracion de sistema completo, (c) evaluacion rigurosa con metricas operacionales no solo offline, (d) honestidad sobre limitaciones, (e) un sistema **funcionando en vivo** validado en condiciones reales.