

Sistema de Pase de Lista por Reconocimiento de Marcha (Gait Recognition)

Resumen Técnico Completo del Proyecto

Pipeline end-to-end basado en GaitBase fine-tuned multisesión
Identificación open-set sobre 19 sujetos con τ calibrado
Despliegue en tiempo real con cámara C920 + GTX 1650

Generado: 06 de May de 2026

Fase actual: 6.4 completada — 6.5 pendiente

Modelo de producción: gaitbase_ft_multisession_best_iter1200.pt

1. Resumen Ejecutivo

Sistema de pase de lista automático que identifica personas mediante el análisis de su forma de caminar (marcha). Utiliza una sola cámara fija (Logitech C920) y un modelo de deep learning especializado (**GaitBase**) fine-tuneado sobre un dataset propio de 19 sujetos. El sistema funciona en tiempo real (~6-8 fps reales) sobre una GPU consumidor (GTX 1650 4GB) y soporta detección **open-set** (rechazo de personas no enroladas).

Métricas finales en producción

Métrica	Valor	Significado
EER (Equal Error Rate)	8.11 %	Punto óptimo TAR=FAR
TAR @ FAR=0 %	86.49 % (32/37)	Aceptación de legítimos sin falsos positivos
Rank-1 cross-session	94.4–94.7 %	Identificación correcta con ropa diferente
Umbral τ producción	0.9847	Recalibrado en vivo
FPS sostenido	~6-8 fps	Pipeline completo en GTX 1650
Latencia confirmación	~6 s	2 secuencias $\times$ 4 s con stride 50 %

Validación open-set en vivo (mayo 2026): persona NO enrolada generó sim=0.9403, correctamente rechazada por estar bajo τ =0.9847 (margen 0.0444). Comportamiento open-set confirmado en condiciones reales.

2. Objetivo del Proyecto

Construir un sistema de **pase de lista automático** basado en reconocimiento de marcha con tres requisitos:

- **Entrada en tiempo real:** cámara fija C920 a 30 fps, decimada a 15 fps
- **Identificación closed-set:** 19 sujetos enrolados, marcaje de presencia automático
- **Identificación open-set:** rechazo de personas fuera de la lista (umbral τ)

¿Por qué Gait Recognition y no reconocimiento facial?

La marcha es una **biometría comportamental**: difícil de falsificar, no requiere cooperación del sujeto, funciona a distancia, y puede operar incluso con la cara obstruida. El estado del arte (post-2023) en este campo está dominado por modelos especializados como **GaitBase**, **DeepGaitV2**, **SkeletonGait++** y **GaitGraph2**, entrenados sobre datasets como CASIA-B, OU-MVLP, Gait3D y CCPG.

Intentos previos descartados

Enfoque previo	Por qué falló
YOLOv8 para identificar	YOLO es detector, no extrae identidad por marcha
ResNet18 sobre frames sueltos	Ignora la dimensión temporal — la esencia de la marcha
BlazePose sin downstream	Solo extrae keypoints, sin modelo que aprenda dinámica
Entrenar desde cero	Dataset pequeño + sin pretrain = fallo garantizado

Decisión estratégica: usar **OpenGait** como framework base + checkpoint preentrenado **GaitBase_Gait3D_120000.pt** (4,000 sujetos) y fine-tunearlo sobre el dataset propio.

3. Stack Tecnológico

Hardware

Componente	Especificación	Uso
GPU principal	NVIDIA GTX 1650 4GB	Inferencia en vivo + entrenamiento Fase 3
GPU alterna	NVIDIA RTX 2060 6GB	Entrenamientos largos Fase 4 (descartada)
CPU	Intel i5-12450H	Procesamiento de I/O, decimación
RAM	16 GB	Buffers y carga de modelos
Cámara	Logitech C920 (1080p@30fps)	Captura para enrolamiento + inferencia

Software (versiones fijadas)

Categoría	Tecnología	Rol
Lenguaje	Python 3.10+	Base
Deep Learning	PyTorch 2.5 + CUDA 12.1 + cuDNN 9	Entrenamiento e inferencia
Framework Gait	OpenGait	Modelo GaitBase + DataLoader CASIA-B
Detección	YOLO11n (ultralytics)	Detector de personas
Segmentación	Robust Video Matting (MobileNetV3)	Siluetas binarias por matting recurrente
Pose	RTMPose-m (rtmlib + onnxruntime-gpu)	17 keypoints COCO
Inferencia ONNX	onnxruntime-gpu	Acelera RTMPose
Visualización	OpenCV + Matplotlib	UI en vivo + reportes

Modelos evaluados (decisión final)

Modelo	Modalidad	Estado	Razón
GaitBase (Gait3D pretrain)	Silueta binaria	✓ EN PRODUCCIÓN	Baseline sólido, suficiente
SkeletonGait++ (multimodal)	Silueta + Pose	✗ Descartado	$\alpha^*=1.0 \rightarrow$ silueta sola gana
ST-GCN lite (Ruta B)	Solo esqueleto	✗ Descartado	Mismo resultado que sólo silueta
DeepGaitV2	Silueta	No probado	GaitBase ya cumple criterios

4. Dataset

Volumen y estructura

Métrica	Valor
Sujetos	19
Sesiones por sujeto	2 (s1 + s2, ropa diferente)
Condiciones por sesión	2 (normal + rápido)
Total videos	75 (1 faltante: jesusantonioaguilarfelix/normal_s2)
Resolución	1920×1080
FPS	30
Duración por video	5 segundos exactos (150 frames)
Frames útiles totales	~3,931 (después de recortar inicio/fin)
Ángulo de cámara	90° lateral (single-view)

Splits subject-disjoint (seed=42)

Split	N	Sujetos
Train	13	brayannajera, carlos carrillo, carlospadilla, cesarvasquez, gilbertofelix, jesusantonioaguilarfelix, jesuscazare, jorge...
Validation	3	hectorsanchez, robertpereira, carlostorres
Test	3	alexbojorquez, jesusvalenzuela, ricardomora

Mosaico visual del dataset (19 sujetos)




Figura: Frame medio del tramo útil de cada sujeto (condición normal). Las siluetas son distinguibles principalmente por estatura aparente y postura — buena señal de variabilidad biométrica.


Limitaciones reconocidas del dataset

- Single-view 90° lateral — sin diversidad angular
- Solo 2 sesiones — variabilidad limitada de ropa
- Mismo escenario, misma cámara, misma iluminación — no generaliza fuera
- 19 sujetos: granularidad métrica de FAR $\approx$ 2.7 %, números frágiles
- Re-encoding mpeg4 previo: pérdida visual ya horneada en los videos
- **Dataset no se puede re-grabar** — limitación operativa aceptada

5. Pipeline de Extracción de Datos (Fase 2)

Pipeline frame-por-frame en GPU que convierte cada video crudo (1920×1080 BGR) en silueta binaria 64×44 + 17 keypoints normalizados, listos para OpenGait.

Diagrama del pipeline



Decisiones técnicas clave

Componente	Elegido	Alternativa	Razón
Detector	YOLO11n	YOLOX-m	Más liviano, ya instalado, suficiente para 1 persona
Segmentación	RVM MobileNetV3	YOLO11-seg	Bordes más limpios, mejor con blur de movimiento
RVM downsample	0.25 (480×270)	0.5 / 1.0	4× más rápido, sin pérdida visual perceptible
Pose runtime	rtmlib + ORT-GPU	mmpose + mmcv	Evita compilación mmcv en Windows+CUDA
Tracker	Ninguno (Fase 2)	ByteTrack	1 persona por escena en grabación
Resize silueta	64×44	128×88	Estándar GaitBase, suficiente para 19 sujetos
Formato salida	.pkl (T,64,44) uint8	Custom dict	Compatible nativo con OpenGait DataLoader

Performance medido

Concepto	Valor
Tiempo total extracción 38 videos (Fase 1)	419 s (~7 min)
Tiempo por video promedio	~11 s (carga inicial + 9 s inferencia + 2 s I/O)
FPS de inferencia en régimen	~17 fps (1920×1080)
VRAM pico	~1.25 GB sobre 4 GB
Carga inicial de modelos (YOLO+RVM+RTMPose)	~5 s

Bug crítico encontrado: onnxruntime-gpu no encontraba cublasLt64_12.dll y caía silenciosamente a CPU (5× más lento). Solución: src/preprocess/_cuda_dlls.py añade <env>/Lib/site-packages/torch/lib/ al PATH antes de importar ORT.

Ejemplo de extracción (16 frames muestreados)




Figura: Debug grid de alexbojorquez/normal: 16 siluetas binarias 64×44 muestreadas del tramo útil después del pipeline YOLO11n + RVM + crop/resize.

6. Arquitectura del Modelo (GaitBase)

Componentes del modelo

Bloque	Descripción
Backbone	ResNet-9 modificado para tensores temporales (T, H, W)
Set Pooling	Agrega información temporal (max+mean) sobre frames
Horizontal Pyramid Pooling	16 strips horizontales → preserva información local por altura
BNNecks	Batch normalization + linear classifier por strip (16 cabezales)
Salida	Embedding (256, 16) — 256-dim por strip × 16 strips

Entrada y salida del modelo

	Forma	Tipo	Descripción
Entrada	(B, T=30/60, 64, 44)	uint8	Secuencia de siluetas binarias
Salida	(B, 256, 16)	float32	Embedding L2-normalizado por strip
Comparación	cosine similarity	—	Sobre embedding aplanado (4096-dim)

Galería (production)

Estructura persistente con embeddings promedio por sujeto:

Archivo	Forma	Contenido
gallery/embeddings.npy	(19, K_max, 256, 16) float32	Multi-template hasta K=4 por sujeto
gallery/valid_mask.npy	(19, K_max) bool	Máscara de templates válidos
gallery/index.json	metadata	Sujetos, ckpt, τ , feat_dim, n_sequences_used

Estrategia de promedio: por cada sujeto, embebér todas las secuencias (4 condiciones × 2 sesiones = hasta 8 templates), L2-norm cada una, promediar, y L2-norm el resultado final. Multi-template con $K \leq 4$ mejora robustez sin requerir re-training.

Curva ROC multi-template (gallery $K \leq 4$ vs single-template)




Figura: Comparativa entre gallery single-template y multi-template ($K \leq 4$). Multi-template estabiliza la similitud y mejora TAR a FAR bajos.

7. Entrenamiento (Fase 3 + 3.5)

Fase 3 — Fine-tuning sesión única

Primer entrenamiento sobre el checkpoint preentrenado. Solo 1 sesión disponible en ese momento.

Hiperparámetro	Valor	Justificación
Pesos iniciales	GaitBase_Gait3D_120000.pt	BNNecks reinicializado, class_num 3000→13
Optimizador	SGD lr=0.01 momentum=0.9 wd=5e-4	LR bajo: fine-tune sobre pretrained estable
Scheduler	MultiStepLR milestones=(750, 1250) $\gamma=0.1$	Decay tardío
Batch	P=4 IDs $\times$ K=2 secuencias = 8 muestras	Solo 2 condiciones por sujeto disponibles
Frames por muestra	30 (random window, fixed_unordered)	Ventana corta, varianza alta
Total iteraciones	1500 (early-stopped a 1000)	Patience=3 evals sin mejora
Eval cada	200 iters	
Loss	TripletLoss(margin=0.2) + CE(scale=16, smooth=0.1)	Triplet push + clasificación
AMP	float16	Reduce VRAM en GTX 1650
Hardware	GTX 1650 4GB, ~1.25 GB usado	98.9 min total

Resultados Fase 3 (best iter 400):

Conjunto	Rank-1	Margen medio	Min margen
Validation (3 sujetos)	100 %	+0.0177	+0.0171
Test intocado (3 sujetos)	100 %	+0.0081	+0.0069
Mejora vs zero-shot	—	2.85 $\times$ val, 2.25 $\times$ test	8.7 $\times$ min margen

Problema descubierto: al evaluar con 2da sesión (ropa diferente), rank-1 cayó de 100 % a 66.7–68.4 %. El modelo había memorizado *silueta-de-la-ropa*, no marcha.

Fase 3.5 — Fine-tuning multisession

Re-entrenamiento mostrando ambas sesiones simultáneamente al modelo. La supervisión cross-clothing fuerza la invariancia a ropa.

Aspecto	Fase 3	Fase 3.5 (multisession)
Fuente train	data/pkl/ (s1)	data/pkl_multisession/ (s1+s2)
Secuencias train	26 (13 $\times$ 2)	51 (13 $\times$ 4 - 1 faltante)
Tipos por sujeto	normal, rapido	normal_s1, normal_s2, rapido_s1, rapido_s2
Triplets	Solo same-clothing	Cross-clothing dentro del batch
Eval metric	rank-1 within-session	margen NR cross-session
Hparams	—	Idénticos a Fase 3
Tiempo total	98.9 min	~177 min (thermal throttling)

Curva de entrenamiento (margen NR validación):

Iter	LR	Triplet	CE	NR rank-1	NR margen
0 (pre)	—	—	—	66.7 %	+0.0005
200	0.01	0.0020	0.606	100 %	+0.0096
400	0.01	0.0000	0.579	100 %	+0.0106
600	0.01	0.0005	0.573	100 %	+0.0113
800	0.001	0.0000	0.568	100 %	+0.0117
1000	0.001	0.0000	0.566	100 %	+0.0116
1200	0.001	0.0000	0.566	100 %	+0.0118 ★
1400	0.0001	0.0000	0.566	100 %	+0.0118 (tie)

Por qué mejoró: con triplets cross-clothing, el TripletLoss enseña al modelo que dos imágenes del mismo sujeto con ropa diferente deben tener embeddings cercanos. El modelo abandona pistas de ropa y aprende dinámica biomecánica de la marcha.

Comparativa cross-session sobre 19 sujetos

Métrica	Pretrained Gait3D	Fase 3 (iter 400)	Fase 3.5 (iter 1200)	Δ vs Fase 3
NN rank-1	72.2 %	66.7 %	94.4 %	+27.7 pp
NN rank-5	94.4 %	100 %	100 %	=
NN margen medio	+0.0015	+0.0037	+0.0222	6.0×
NR rank-1	57.9 %	68.4 %	94.7 %	+26.3 pp
NR rank-5	84.2 %	94.7 %	100 %	+5.3 pp
NR margen medio	+0.0006	+0.0025	+0.0204	8.2×

Único error remanente: ricardomora → hectorsanchez (build corporal muy similar). Documentado y aceptado como limitación. Pose podría resolverlo, pero el costo/beneficio no justifica la integración (ver Fase 4).

8. Fase 4 — Multimodal (CERRADA como Caso C)

Se evaluaron dos rutas para integrar pose en el sistema:

- **Ruta A:** SkeletonGait++ con init de GaitBase
- **Ruta B:** ST-GCN lite (rama de pose pura) + fusión tardía

Resultado: ambas convergen a $\alpha^*=1.0$ (silueta sola gana en open-set). Causa raíz: dataset acotado (19 sujetos, 90° lateral, 2 sesiones) — la pose no agrega información discriminativa que la silueta no tenga ya.

Reinterpretación del requisito multimodal del CLAUDE.md: pose se calcula en runtime para **quality gating** (descartar frames con keypoints malos) y **tracking**, NO para fusión en score. Esto preserva el espíritu del requisito sin pagar el costo de Fase 4.

9. Evaluación Open-Set (Fase 5)

Sobre el modelo de Fase 3.5, se calibró un umbral τ tal que: si $\text{sim_top1} \geq \tau$ y $\text{top1} == \text{identidad correcta} \rightarrow$ aceptar (TAR); si $\text{sim_top1} < \tau \rightarrow$ rechazar (correcto si el probe es desconocido).

Protocolo Leave-One-Subject-Out (LOSO)


- 19 sujetos, sweep de τ con 2001 puntos
- Genuines: 18 NN + 19 NR = **37 pares**
- Impostores: 18 NN + 19 NR = **37 pares** (cada probe contra gallery sin su identidad)
- Operating points: EER, $\tau@FAR=0\%$, $\tau@FAR \leq 1\%$, $\tau@FAR \leq 5\%$

Resultados (protocolo ALL = NN + NR)


Métrica	Pretrained Gait3D	ft_multisession_iter1200
EER	48.65 %	8.11 %
TAR @ FAR=0 %	16.22 %	86.49 %
TAR @ FAR≤1 %	16.22 %	86.49 %
TAR @ FAR≤5 %	18.92 %	86.49 %
Gap means (genuine – impostor)	+0.0016	+0.0217
Genuine sim mean / std	0.9907 / 0.0024	0.9883 / 0.0054
Impostor sim mean / std	0.9890 / 0.0024	0.9666 / 0.0113

Lectura: el pretrained es inservible en open-set (distribuciones casi solapadas, gap=ruido). La supervisión multisession separó las distribuciones **13x**, llevando EER de 48.65 % a 8.11 %. Criterio de salida $\geq 80\%$ superado.

Curvas ROC: pretrained vs fine-tuned multisession



Pretrained Gait3D
EER=48.65 %



ft_multisession_iter1200
EER=8.11 %

La curva ROC del modelo fine-tuned se acerca al codo superior-izquierdo (TAR alto, FAR bajo), mientras que la del pretrained es prácticamente diagonal (clasificación al azar en open-set).


Política de τ adoptada

Perfil	τ	TAR	FAR esperado	Cuándo usar
Conservador	0.9807	86.49 %	0 %	Alta seguridad (default Fase 5)
Producción actual	0.9847	86.49 %	0 % absoluto	Recalibrado para 0 % en pase real
Balanceado	0.9789	≈ 92 %	≈ 8 %	Protoproducción

10. Pipeline de Inferencia en Vivo (Fase 6)

9 módulos secuenciales que conectan la cámara C920 con la decisión final de pase de lista.

Diagrama de bloques



Parámetros de operación (configs/pipeline.yaml)

Parámetro	Valor	Propósito
camera.target_fps	15	Decimación 30→15 fps (50% menos cómputo)
detector.conf	0.5	Threshold YOLO11n para persona
tracker.warmup_frames	15	1 segundo de bbox estable antes de acumular
tracker.reset_frames	15	1 segundo sin bbox → reset buffer
tracker.iou_min	0.3	Continuidad bbox entre frames
sequence.window	60 frames	4 segundos de marcha (a 15 fps)
sequence.stride	30 frames	Solapamiento 50 %, emisión cada 2 s
embedder.ckpt	iter1200	Modelo en producción
matcher.tau	0.9847	Recalibrado para FAR=0 % en vivo
confirmation.n_consecutive	2	2 secuencias seguidas con mismo top-1

Latencia esperada por etapa (GTX 1650)

Etapas	Tiempo	Notas
Capture + decimate	~2 ms	OpenCV
YOLO11n detect	~12 ms	Sin TensorRT
RVM segment	~25 ms	MobileNetV3, 480×270 interno
SeqBuffer push	<1 ms	numpy roll
GaitBase forward (60,64,44)	~15 ms	Batch 1

Etapa	Tiempo	Notas
Match cosine	<1 ms	Dot product 19×4096
Total por frame	~40 ms	Margen sobre 66 ms (15 fps)
Total por confirmación	~6 s	2 secuencias × 4 s con stride

Estructura de carpetas y archivos

src/pipeline/

■■■ capture.py ■■■ detect.py ■■■ track.py
■■■ segment.py ■■■ seq_buffer.py ■■■ embed.py
■■■ match.py ■■■ confirm.py ■■■ log.py
■■■ types.py (BBox, MatchResult, etc.)

scripts/

■■■ build_gallery.py (Fase 6.2)
■■■ infer_video.py (Fase 6.3 – modo offline)
■■■ infer_live.py (Fase 6.4 – cámara + UI)

configs/pipeline.yaml

gallery/{embeddings.npy, valid_mask.npy, index.json}

logs/attendance_YYYY-MM-DD.csv

11. Roadmap por Fases

Fase	Descripción	Estado	Entregable clave
0	Setup + descubrimiento de requisitos	✓ Cerrada	REQUISITOS.md
1	Auditoría del dataset crudo	✓ Cerrada	01_dataset_audit.md
2	Preparación: extracción + splits + pkl	✓ Cerrada	data/pkl/, data/pkl_multisession/
3	Fine-tuning GaitBase sesión única	✓ Cerrada	gaitbase_ft_best_iter400.pt
3.5	Fine-tuning multisesión	✓ Cerrada	gaitbase_ft_multisession_best_iter1200.pt ★
4	Modelo multimodal (silueta+pose)	✗ Cerrada (Caso C)	PHASE4_CIERRE — descartado
5	Open-set con umbral τ	✓ Cerrada	06_openset_eval.md, $\tau=0.9807$
6.1	Diseño del pipeline en vivo	✓ Cerrada	14_pipeline_design.md
6.2	Build gallery	✓ Cerrada	gallery/embeddings.npy
6.3	Inferencia offline (video)	✓ Cerrada	scripts/infer_video.py
6.4	Inferencia en vivo + UI	✓ Cerrada	scripts/infer_live.py
6.5	Validación end-to-end formal	■ Pendiente	TPR/FPR real, latencia
7	Optimización y despliegue	■ Siguiente	INT8/TensorRT, SQLite, manual

12. Limitaciones y Trabajo Futuro

Limitaciones reconocidas (no resueltas)

- **ricardomora** ↔ **hectorsanchez**: 1 par confunde NN y NR — build corporal idéntico
- **Granularidad FAR**: $1/37 \approx 2.7\%$ con 19 sujetos. Producción con 50+ requiere recalibración
- **2 sesiones**: ropa C → degradación esperada. Mitigación: 3ra sesión (out of scope)
- **Cambio de cámara**: requiere recalibración de τ
- **Single-view 90° lateral**: no funciona con otros ángulos sin re-training
- **τ frágil**: impostores peores tienen sim 0.9807 (justo en el borde)

Fase 6.5 — Validación End-to-End (pendiente)

- Pruebas formales con los 19 sujetos enrolados — TPR/FPR real
- Robustez: ropa diferente a s1/s2, velocidad variable, iluminación distinta
- Múltiples personas desconocidas en distintas condiciones
- Latencia real por identificación en escenario de clase
- Criterio de éxito: $TPR \geq 85\%$, $FPR \leq 5\%$, latencia ≤ 8 s, FPS ≥ 12

Fase 7 — Optimización y Despliegue (siguiente)

- **Quantización INT8 / TensorRT**: objetivo embedding en ~ 30 ms vs ~ 100 ms actual
- **SQLite**: reemplazar CSV para log persistente con consultas históricas
- **Documentación final**: manual de instalación, guía de calibración de τ
- **UI mejorada**: wrapper Streamlit/Gradio para demo (opcional)

Conclusión: el sistema está listo para demo y operación cotidiana en el aula objetivo. La validación open-set en vivo confirmó margen holgado ($\Delta=0.0444$ entre desconocido y τ). Fase 6.5 formaliza las métricas y Fase 7 lleva el sistema a producción optimizada.